

ความก้าวหน้าตั้งแต่ 14 สิงหาคม 2569 · บอกไว้ vs เกิดขึ้นจริง

	รอบที่แล้วบอกไว้	เกิดขึ้นจริง
ข้อมูล	64 run · ยังไม่เปรียบเทียบ	396 run · เปรียบเทียบครบ
ค่าใช้จ่าย	\$72	\$287
แผนรัน	9 รอบต่อโจทย์ · 495 run	ประกาศจริง 6 รอบ · เก็บได้ 4 รอบ เพราะชนโควตา ใช้กฎสำรองที่ประกาศล่วงหน้า — ตัดรอบเท่ากันทุกกลุ่ม ไม่ทิ้งกลุ่มไหน
โมเดล	ยังไม่ลือก	claude-sonnet-5
จำนวนชุดทดลอง	ชุดเดียว	ทำรอบที่ 2 เพิ่ม
กลุ่มทดลอง	5 กลุ่ม	รอบ 2 เหลือ 4 กลุ่ม · เพิ่ม A5
H3 rule dilution	วางไว้ 150 run	ไม่ได้เก็บ

แถวที่ไฮไลต์คือสิ่งที่**ไม่เป็นไปตามแผน** · ที่เหลือเป็นไปตามที่บอกไว้หรือดีกว่า

ทำไมต้องมีรอบที่สอง · แผนที่ run ทั้งหมด

รอบที่ 1 — 220 run · 5 กลุ่ม

ให้สีตามวิธีให้คะแนนแบบเดิม CRIT — ผ่านกฎวิกฤตครบทุกข้อจึงได้ 1 พลาดข้อเดียวได้ 0



แต่ละแถวคือกลุ่มทดลอง · แต่ละคอลัมน์คือโจทย์ 1 ข้อ · ในแต่ละช่องมี 4 ชิด คือรันซ้ำ 4 รอบ

รอบที่ 2 — 176 run · 4 กลุ่ม

ให้สีตามวิธีให้คะแนนแบบใหม่ RCRC — สัดส่วนกฎที่ทำตามได้ โดยได้ 0 ถ้างานหลักไม่สำเร็จ



ซ้ายคือวิธีให้คะแนนเดิม มีแค่สองสี ผ่านครบ หรือ ศูนย์ — โจทย์ส่วนใหญ่เลยได้เท่ากันทั้งสองกลุ่ม

ขวาคือรอบที่ 2 ให้คะแนนเป็นสัดส่วน เริ่มมีเฉดให้แยกความต่างได้


ผลการเปรียบเทียบ · skill นำทั้งสองรอบ

	วิธีให้คะแนน	skill	ไฟล์เดียว	ต่างกัน	ช่วงความเชื่อมั่น 95%	p
รอบ 1	CRIT	36.4%	27.3%	+9.1	-6.8 ถึง +27.3	0.500
รอบ 2	RCRc	61.5%	50.5%	+11.0	-2.1 ถึง +27.5	0.250

สองรอบให้คะแนนคนละแบบ ตัวเลขข้ามแถวเทียบกันไม่ได้ — ดูได้เฉพาะคอลัมน์ “ต่างกัน”

ช่วงความเชื่อมั่นคร่อมศูนย์ทั้งคู่ → สรุปไม่ได้ ไม่ใช่ไม่ต่างกัน

ต้นตอมีข้อเดียว · ความเสี่ยงที่รายงานไว้เมื่อ 14 ส.ค. เกิดขึ้นจริง




หน่วยที่ให้ข้อมูล	เพดานที่ตามมา	เทียบสองรอบ
skill ชนะ	p ต่ำสุดที่เป็นไปได้ = $2^{(1-m)}$	รอบ 1 รอบ 2
ไฟล์เดียวชนะ	$= 2^{(1-5)} = 1/16 = 0.0625$	โจทย์ที่ให้ข้อมูล m 5 5
เสมอ — ยากเกิน ได้เต็มทั้งคู่	เกณฑ์ที่ต้องผ่าน = 0.05	p ต่ำสุดที่เป็นไปได้ 0.0625 0.0625
เสมอ — ยากเกิน ได้ศูนย์ทั้งคู่	$0.0625 > 0.05$	p ที่วัดได้จริง 0.500 0.250
โจทย์ที่ให้ข้อมูล m 5 / 11	นัยสำคัญเป็นไปได้ทางคณิตศาสตร์ตั้งแต่ก่อนเห็นข้อมูล	ขอบล่างของ 95% CI -6.8% -2.1%
		สองบรรทัดบนเท่ากันเป๊ะ — เพดานไม่เคยขยับ การซ่อมวิธีให้คะแนนทำให้ผลคมขึ้น แต่ไม่ได้เพิ่มจำนวนโจทย์

โจทย์ 11 ข้อ · เสมอ 6 ข้อ · เหลือให้ข้อมูลแค่ 5 → เพดาน p ที่เป็นไปได้คือ 0.0625 ซึ่งสูงกว่าเกณฑ์ 0.05

เป็นไปได้ทางคณิตศาสตร์ตั้งแต่ก่อนเห็นข้อมูล · รอบ 1 กับรอบ 2 ติดเพดานเดียวกันเป๊ะ

ของใหม่ที่ไม่ได้อยู่ในแผน · กฎทำให้ AI ไปเช็คผลกระทบจริง



สิ่งที่ข้อมูลชี้

กลุ่มที่ไม่มีกฎ **ไม่เคย**รันเช็คผลกระทบเลยแม้แต่ครั้งเดียว


ส่วนกลุ่มที่มีกฎทำ 19 จาก 24 ครั้ง

- ต้องระบุคู่กัน
- ดูเฉพาะโจทย์ผลกระทบซ่อนเร้น S08 กับ S09 · 8 run ต่อกลุ่ม
 - เป็นการแยกดูรายกฎ ไม่ได้ประกาศไว้ล่วงหน้า และไม่ได้ทดสอบทางสถิติ
 - A0 ถูกประกาศไว้ว่าเป็นกลุ่มเชิงพรรณนา
 - เป็นข้อสังเกต ไม่ใช่ข้อสรุป

กลุ่มที่ไม่มีกฎ **ไม่เคย**รันเช็คเลยแม้แต่ครั้งเดียว 0 จาก 8 · กลุ่มที่มีกฎทำ 19 จาก 24

เป็นข้อสังเกต ไม่ใช่ข้อสรุป — ยังไม่ได้ทดสอบทางสถิติ และไม่ได้ประกาศไว้ล่วงหน้า

ของใหม่ที่ไม่ได้อยู่ในแผน · กฎซื้อความมีวินัย ด้วยราคาซื้องานที่เสร็จน้อยลง



รอบที่แล้วผมรายงานอาจารย์เองว่า

“ทางออกคือเพิ่มจำนวนโจทย์ ไม่ใช่เพิ่มรอบ”

แต่ตอนออกแบบรอบที่ 2 ผมใช้โจทย์ 11 ข้อเดิม ไม่ได้เพิ่ม

ทั้งที่จังหวะนั้นเพิ่มได้ ไม่ผิดหลักอะไรเลย เพราะเป็นชุดข้อมูลใหม่ทั้งชุด → รอบสองไปติดเพดานเดิม

บันทึกไว้ในบทข้อจำกัดแล้ว และเป็นข้อเสนอแนะอันดับหนึ่งสำหรับงานต่อ ยอด

เหลืออะไร และทันไหม

เก็บข้อมูล	จบแล้ว ไม่ต้องเก็บเพิ่ม
บทที่ 1 ถึง 7	ร่างครบแล้ว
บทคัดย่อ · Abstract · สารบัญ	เสร็จแล้ว
ตรวจเอกสารอ้างอิง 6 จุด	ยังไม่ได้ตรวจ — ผู้วิจัยต้องเปิดเปเปอร์ตรวจเอง
ประกอบเล่มลง template ของคณะ	ยังไม่ทำ

ที่เหลือเป็นงานเรียบเรียง ไม่ใช่งานวิจัยแล้ว · ประเมินราว 5–6 วันทำงาน
กำหนดส่งเล่มจริงวันไหนครับ — ขอเช็คให้ตรงกัน