


ความก้าวหน้าตั้งแต่ 14 สิงหาคม 2569 · บอกไว้ vs เกิดขึ้นจริง

	รอบที่แล้วบอกไว้	เกิดขึ้นจริง
ข้อมูล	64 run · ยังไม่เปรียบเทียบ	396 run · เปรียบเทียบครบ
ค่าใช้จ่าย	\$72	\$287
แผนรัน	9 รอบต่อโจทย์ · 495 run	ประกาศจริง 6 รอบ · เก็บได้ 4 รอบ เพราะชนโควตา ใช้กฎสำรองที่ประกาศล่วงหน้า — ตัดรอบเท่ากันทุกกลุ่ม ไม่ทิ้งกลุ่มไหน
โมเดล	ยังไม่ลือก	claude-sonnet-5
จำนวนชุดทดลอง	ชุดเดียว	ทำรอบที่ 2 เพิ่ม
กลุ่มทดลอง	5 กลุ่ม	รอบ 2 เหลือ 4 กลุ่ม · เพิ่ม A5
H3 rule dilution	วางไว้ 150 run	ไม่ได้เก็บ

แถวที่ไฮไลต์คือสิ่งที่**ไม่เป็นไปตามแผน** · ที่เหลือเป็นไปตามที่บอกไว้หรือดีกว่า

ทำไมต้องมีรอบที่สอง · แผนที่ run ทั้งหมด



ซ้ายคือวิธีให้คะแนนเดิม มีแค่สองสี ผ่านครบ หรือ ศูนย์ — โจทย์ส่วนใหญ่เลยได้เท่ากันทั้งสองกลุ่ม

ขวาคือรอบที่ 2 ให้คะแนนเป็นสัดส่วน — เฉดที่เพิ่มมามีแค่ 34 จาก 176 run อีก 142 ยังเป็น 0 หรือ 1 เป๊ะ · พอให้ p ขยับจาก 0.500 เป็น 0.250 แต่ m ยังเท่าเดิมที่ 5

ผลการเปรียบเทียบ · A2 (skill) เทียบ A1 (ไฟล์เดียว) — คู่มือที่ประกาศไว้ล่วงหน้า



ตัวอย่างโจทย์ S04 — A2 รันสี่รอบได้ 0 · 1 · 1 · 1 เฉลี่ย **0.750** · A1 ได้ 0 · 0 · 0 · 0 เฉลี่ย **0.000** → ผลต่าง **+0.750** · เฉลี่ยผลต่างทั้ง 11 โจทย์ = **+11.0 จุด** คือคอลัมน์ “ต่างกัน”


	วิธีให้คะแนน	A2 skill	A1 ไฟล์เดียว	ต่างกัน	ช่วงความเชื่อมั่น 95%	p
รอบ 1	CRIT	36.4%	27.3%	+9.1	-6.8 ถึง +27.3	0.500
รอบ 2	RCRc	61.5%	50.5%	+11.0	-2.1 ถึง +27.5	0.250

สองรอบให้คะแนนคนละแบบ **ตัวเลขข้ามแถวเทียบกันไม่ได้** — ดูได้เฉพาะคอลัมน์ “ต่างกัน”

ช่วงความเชื่อมั่นคร่อมศูนย์ทั้งคู่ → **สรุปไม่ได้ ไม่ใช่ไม่ต่างกัน**

คู่มือ **A5 เทียบ A2** — ข้อความชุดเดียวกัน ต่างแค่โหลดตลอด vs โหลดตามเงื่อนไข = **-8.8 จุด** · CI -25.8 ถึง +5.5 · p = 0.4375 · **ประตูไม่เปิด** เพราะคู่มือไม่นัยสำคัญ อ้างไม่ได้

ต้นตอมีข้อเดียว · ความเสี่ยงที่รายงานไว้เมื่อ 14 ส.ค. เกิดขึ้นจริง



หน่วยที่ให้ข้อมูล

skill ชนะ	3
ไฟล์เดียวชนะ	2
เสมอ — ยากเกิน ได้เต็มทั้งคู่	3
เสมอ — ยากเกิน ได้ศูนย์ทั้งคู่	3

โจทย์ที่ให้ข้อมูล m

5 / 11

เพดานที่ตามมา

p ต่ำสุดที่เป็นไปได้ = $2^{(1-m)}$
 $= 2^{(1-5)} = 1/16 = 0.0625$
เกณฑ์ที่ต้องผ่าน = 0.05
 $0.0625 > 0.05$

เงื่อนไขนี้ประกาศไว้ก่อนเก็บข้อมูล
พอ m ออกมา 5 ผลถูกล็อกทันที ก่อนดูค่า p ด้วยซ้ำ


เทียบสองรอบ

	รอบ 1	รอบ 2
โจทย์ที่ให้ข้อมูล m	5	5
p ต่ำสุดที่เป็นไปได้	0.0625	0.0625
p ที่วัดได้จริง	0.500	0.250
ขอบล่างของ 95% CI	-6.8%	-2.1%

สองบรรทัดบนเท่ากันเป๊ะ — เพดานไม่เคยขยับ
การซ่อมวิธีให้คะแนนทำให้ผลคมขึ้น แต่ไม่ได้เพิ่มจำนวนโจทย์

โจทย์ 11 ข้อ · เสมอ 6 ข้อ · เหลือให้ข้อมูลแค่ 5 → เพดาน p ที่เป็นไปได้คือ 0.0625 ซึ่งสูงกว่าเกณฑ์ 0.05

เงื่อนไขนี้ประกาศไว้ก่อนเก็บข้อมูลว่า ถ้า m ต่ำกว่า 6 นั้นสำคัญจะเป็นไปไม่ได้ พอ m ออกมา 5 ผลถูกล็อกทันที ก่อนดูค่า p ด้วยซ้ำ · รอบ 1 กับรอบ 2 ติดเพดานเดียวกันเป๊ะ



สิ่งที่ข้อมูลชี้

กลุ่มที่ไม่มีกฎ **ไม่เคย**รันเช็คผลกระทบเลยแม้แต่ครั้งเดียว


ส่วนกลุ่มที่มีกฎทำ 19 จาก 24 ครั้ง

- ต้องระบุกัน
- ดูเฉพาะโจทย์ผลกระทบซ่อนเร้น S08 กับ S09 · 8 run ต่อกลุ่ม
 - เป็นการแยกดูรายกฎ ไม่ได้ประกาศไว้ล่วงหน้า และไม่ได้ทดสอบทางสถิติ
 - A0 ถูกประกาศไว้ว่าเป็นกลุ่มเชิงพรรณนา
 - เป็นข้อสังเกต ไม่ใช่ข้อสรุป

กลุ่มที่ไม่มีกฎ **ไม่เคย**รันเช็คเลยแม้แต่ครั้งเดียว 0 จาก 8 · กลุ่มที่มีกฎทำ 19 จาก 24

เป็นข้อสังเกต ไม่ใช่ข้อสรุป — ยังไม่ได้ทดสอบทางสถิติ และไม่ได้ประกาศไว้ล่วงหน้า

ของใหม่ที่ไม่ได้อยู่ในแผน · กฎซื้อความมีวินัย ด้วยราคาซื้องานที่เสร็จน้อยลง



คุมตัวแปรยังงៃ · สองอย่างที่ตรวจจับได้จริง ไม่ใช่เขียนไว้เฉย ๆ

กลไก	เกิดอะไรขึ้น
ดักการเขียนหน่วยความจำถาวร 19 ก.ย. · run S07-weekly-quota__A1__r3	เอเจนต์กลุ่ม A1 เขียนไฟล์ นอกโฟลเดอร์ทดลอง — ในไฟล์มีทั้งสรุปกฎของกลุ่มตัวเอง และเฉลยของ S07 ซึ่งเป็นโจทย์ที่ไม่มีใครทำสำเร็จเลย จับได้ทันทีที่ run จบ · หยุดทั้งชุด · run ถูกปฏิเสธ · ไม่มี run ถัดไปได้อ่าน หลักฐานเก็บครบที่ evidence/memory-contamination-2026-09-19/
ตรวจว่า skill โหลดถูกจังหวะไหม trigger F1 ของ A2 · ชุดที่ 2	trace-to-requirement 1.000 · acceptance-first 0.842 · impact-analysis 0.872 ชุด sensitivity ของ Amendment 16 ให้ impact-analysis 0.593 — ต้องรายงานคู่กันเสมอ

กลไกส่งกฎหมายงานถูกจังหวะ แต่ผลปลายทางไม่ขยับ → ปัญหาไม่ได้อยู่ที่การส่งกฎ

และต้องพูดตรง ๆ ว่า กลไกจับได้เพราะมีคนเฝ้าไว้ล่วงหน้า — เราไม่รู้ว่ายังมีช่องแบบเดียวกันที่ยังไม่มีใครนึกถึงอีกกี่ช่อง

รอบที่แล้วผมรายงานอาจารย์เองว่า

“ทางออกคือเพิ่มจำนวนโจทย์ ไม่ใช่เพิ่มรอบ”

แต่ตอนออกแบบรอบที่ 2 ผมใช้โจทย์ 11 ข้อเดิม ไม่ได้เพิ่ม

ทั้งที่จังหวะนั้นเพิ่มได้ ไม่ผิดหลักอะไรเลย เพราะเป็นชุดข้อมูลใหม่ทั้งชุด → รอบสองไปติดเพดานเดิม

บันทึกไว้ในบทข้อจำกัดแล้ว และเป็นข้อเสนอแนะอันดับหนึ่งสำหรับงานต่อ ยอด

เหลืออะไร และทันไหม

เก็บข้อมูล	จบแล้ว ไม่ต้องเก็บเพิ่ม
บทที่ 1 ถึง 7	ร่างครบแล้ว
บทคัดย่อ · Abstract · สารบัญ	เสร็จแล้ว
ตรวจเอกสารอ้างอิง — ติดธงไว้ 4 จุด แต่ต้องอ่านต้นฉบับครบ 12 รายการ	ยังไม่ได้ตรวจ — ผู้วิจัยต้องเปิดเปเปอร์เอง ≈ 1 วัน
ประกอบเล่มลง template ของคณะ + สารบัญตาราง 65 ตาราง	ยังไม่ทำ ≈ 2–3 วัน
ทำสไลด์ฉบับสมบูรณ์สำหรับสอบป้องกัน	ยังไม่ทำ ≈ 2 วัน

ที่เหลือเป็นงานเรียบเรียง ไม่ใช่งานวิจัยแล้ว · สามแถวล่างรวมกัน ราว 5–6 วันทำงาน

กำหนดส่งเล่มจริงวันไหนครับ — ขอเช็คให้ตรงกัน