

รายงานความก้าวหน้า ครั้งที่ 2 · 22 กันยายน 2569

การควบคุมพฤติกรรม LLM Agent ในงานพัฒนาระบบ ด้วย **Context Engineering** และ ระบบทักษะเอเจนต์

477-401 สัมมนาาระบบสารสนเทศทางธุรกิจ

ธีรภาพ 6610510149 · ธีรภัทร์ 6610510148

1 · วันนี้มาทำอะไร

ความก้าวหน้าตั้งแต่ 14 สิงหาคม

ครั้งที่แล้ว

เครื่องมือวัดเสร็จ เก็บ calibration 64 run · ยังไม่ได้เปรียบเทียบระหว่างกลุ่มเลย

วันนี้


เก็บข้อมูลจบแล้ว **396 run** · เปรียบเทียบครบ **2 ชุด** · ร่างรายงานครบ **7 บท** พร้อมบทคัดย่อ Abstract และสารบัญ

มีหลายอย่างไม่เป็นไปตามแผน จะเล่าให้ฟังทีละข้อ

บอกไว้ **vs** เกิดขึ้นจริง

	รอบที่แล้วบอกไว้	เกิดขึ้นจริง
ข้อมูล	64 run · ยังไม่เปรียบเทียบ	396 run · เปรียบเทียบครบ
ค่าใช้จ่าย	\$72	\$287
แผนรัน	9 รอบต่อโจทก์ · 495 run	ประกาศจริง 6 รอบ · เก็บได้ 4 รอบ เพราะชนโควตา ใช้กฎสำรองที่ประกาศล่วงหน้า — ตัดรอบเท่ากันทุกกลุ่ม ไม่ทิ้งกลุ่มไหน
โมเดล	ยังไม่ล็อก	claude-sonnet-5
จำนวนชุดทดลอง	ชุดเดียว	ทำรอบที่ 2 เพิ่ม — ไม่ได้อยู่ในแผน
กลุ่มทดลอง	5 กลุ่ม	รอบ 2 เหลือ 4 กลุ่ม · เพิ่ม A5
H3 rule dilution	วางไว้ 150 run	ไม่ได้เก็บ

ทำไมต้องมีการทดลองรอบที่ 2



วิธีให้คะแนนของเราเองยังมีปัญหา — ตัวเดิมบังคับว่าต้องผ่านกฎวิกฤตครบทุกข้อจึงได้คะแนน พลาดข้อเดียวได้ศูนย์ · ซ้ายมีแค่สองสี ขวามีเฉด

รู้ว่าดูไม่ดี จึงกันตัวเองไว้สามชั้น

- เหตุผลที่เปลี่ยนไม่ใช่เพราะผลไม่สวย แต่เพราะตัวเดิมนับกฎที่ไม่เคยถูกทดสอบเลยว่าผ่าน ซึ่งเป็นการวัดที่ผิดอยู่แล้ว ควรซ่อมไม่ว่าผลจะออกทางไหน
- ตั้งด่านทดสอบตัวใหม่ที่ลึ้มได้ เอา AI ปลอมที่ไม่ทำงานเลยป้อนเข้าไป ต้องได้คะแนนใกล้เคียงศูนย์ ถ้าไม่ผ่านก็ใช้ตัวชี้วัดนี้ไม่ได้
- ประกาศแผนใหม่ลงวันที่ก่อนเก็บข้อมูลรอบสอง และเขียนไว้ตรง ๆ ว่าเขียนหลังเห็นผลรอบแรกแล้ว เห็นอะไรไปบ้าง • ผลรอบแรกยังอยู่ในเล่มครบ ไม่ได้ลบ

และที่สำคัญ — ผลทั้งสองรอบยังสรุปไม่ได้เหมือนกัน การเปลี่ยนไม่ได้ทำให้ผลสวยขึ้น

skill นำทั้งสองรอบ แต่ยังไม่ฟันธงไม่ได้

	วิธีให้คะแนน	skill	ไฟล์เดียว	ต่างกัน	ช่วงความเชื่อมั่น 95%	p
รอบ 1	CRIT	36.4%	27.3%	+9.1	-6.8 ถึง +27.3	0.500
รอบ 2	RCRc	61.5%	50.5%	+11.0	-2.1 ถึง +27.5	0.250

สองรอบใช้วิธีให้คะแนนคนละแบบ ตัวเลขข้ามแถวเทียบกันไม่ได้ — ดูได้เฉพาะคอลัมน์ “ต่างกัน” ซึ่งเป็นการเทียบภายในรอบเดียวกัน

ช่วงความเชื่อมั่นครอบคลุมทั้งคู่
ต้องพูดว่า “สรุปไม่ได้” ไม่ใช่ “ไม่ต่างกัน” — “ไม่ต่างกัน” แปลว่าพิสูจน์แล้วว่าเท่ากัน ซึ่งเราไม่ได้พิสูจน์ เราแค่ยังไม่แยกไม่ออก

ทำไมยังฟันธงไม่ได้ — ความเสี่ยงที่รายงานไว้ 14 ส.ค. เกิดขึ้นจริง




โจทย์ที่ให้ข้อมูลมีแค่ 5 จาก 11

- รอบที่แล้วรายงานว่ ICC วัดได้ 0.335 เพดานข้อมูลต้นที่ 33 หน่วยต่อกลุ่ม และทางเดียวที่จะทะลุเพดานคือเพิ่มจำนวนโจทย์ ไม่ใช่เพิ่มรอบ
- การทดสอบนับ โจทย์ เป็นหน่วยข้อมูล ไม่ใช่นับ run — หน่วยคือ 11 ไม่ใช่ 176
- โจทย์ 11 ข้อ มี 6 ข้อที่ผลต่างเป็นศูนย์สนิท — สามข้อง่ายเกินไปได้เต็มทั้งคู่ อีกสามข้อยากเกินไปได้ศูนย์ทั้งคู่
- เหลือโจทย์ที่ให้ข้อมูล 5 ข้อ ซึ่งทำให้ ค่า p ต่ำที่สุดที่เป็นไปได้คือ 0.0625 ซึ่งมากกว่าเกณฑ์ 0.05

ต่อให้ skill ชะรวดทั้ง 5 ข้อ ก็ยังไม่ผ่านเกณฑ์อยู่ดี — เป็นไปไม่ได้ทางคณิตศาสตร์ตั้งแต่ก่อนเห็นข้อมูล


รอบที่ 2 ได้ 5 ข้อเท่าเดิม · การขอมวิธีให้คะแนนทำให้ผลคมขึ้นจาก 0.500 เหลือ 0.250 แต่ไม่ได้แก้เรื่องจำนวนโจทย์

กฎทำให้ AI ไปเช็คผลกระทบจริง



เป็นข้อสังเกต ไม่ใช่ข้อสรุป — ยังไม่ได้ทดสอบทางสถิติ และไม่ได้ประกาศไว้ล่วงหน้า

กฎข้อความมีวินัย ด้วยราคาคือความสำเร็จของงาน



สิ่งที่พลาด

รอบที่แล้วผมรายงานอาจารย์เองว่า “ทางออกคือเพิ่มจำนวนโจทย์ ไม่ใช่เพิ่มรอบ”

แต่ตอนออกแบบรอบที่ 2 กลับใช้โจทย์ 11 ข้อเดิม ไม่ได้เพิ่ม

- ทั้งที่จังหวะนั้นเพิ่มได้ ไม่ผิดหลักอะไรเลย เพราะเป็นชุดข้อมูลใหม่ทั้งชุด และเขียนกฎการเพิ่มโจทย์เตรียมไว้ในเอกสารประกาศแผนแล้วด้วยซ้ำ
- ผลคือ รอบที่ 2 ไปติดเพดานเดิม
- เหตุผลตอนนั้นคือเวลาและโควตา — โจทย์ใหม่หนึ่งข้อต้องผ่านด้านตรวจสอบด้าน และเพิ่ม 5 ข้อหมายถึงรันเพิ่มอีก 80 run
- มองย้อนกลับไปคือตัดสินใจผิด บันทึกไว้ในบทข้อจำกัดแล้ว และเป็นข้อเสนอแนะอันดับหนึ่งสำหรับงานต่อ ยอด

เหลืออะไร และทันไหม

เก็บข้อมูล	จบแล้ว ไม่ต้องเก็บเพิ่ม
บทที่ 1 ถึง 7	ร่างครบแล้ว
บทคัดย่อ · Abstract · สารบัญ	เสร็จแล้ว
ตรวจเอกสารอ้างอิง 6 จุด	ยังไม่ได้ตรวจ — ผู้วิจัยต้องเปิดเปเปอร์ตรวจเอง
ประกอบเล่มลง template ของคณะ	ยังไม่ทำ

ที่เหลือเป็นงานเรียบเรียง ไม่ใช่งานวิจัยแล้ว

ประเมินว่า **ทันวันที่ 10 ตุลาคม**