

เรื่อง การควบคุมพฤติกรรม LLM Agent ในงานพัฒนาระบบด้วย Context
Engineering และระบบทักษะเอเจนต์
Controlling LLM Agent Behavior in Software Development via
Context Engineering and Agent Skills

จัดทำโดย

นาย ชีรภัทร์ ชินวุฒิมวงศ์ 6610510148

นาย ชีรภาพ บุญศรี 6610510149

อาจารย์ที่ปรึกษา

ผู้ช่วยศาสตราจารย์ ดร.รุชดี บิลหมัด

รายงานฉบับนี้เป็นส่วนหนึ่งของรายวิชา 477-401 สัมมนา ระบบสารสนเทศทางธุรกิจ

(Seminar in Business Information System)

ภาคเรียนที่ 1 ปีการศึกษา 2569

วิชาเอกระบบสารสนเทศทางธุรกิจ สาขาวิชาบริหารธุรกิจ คณะวิทยาการจัดการ มหาวิทยาลัยสงขลานครินทร์

สารบัญ

1. บทนำ	- 5 -
1.1. คำถามวิจัยและสมมติฐาน	- 5 -
1.1.1. คำถามวิจัยหลัก	- 5 -
1.1.2. ข้อเสนอหลักและสมมติฐานย่อย	- 5 -
2. ระเบียบวิธีวิจัยและระบบทดลอง	- 6 -
2.1. การออกแบบกลุ่มทดลอง (5 กลุ่ม)	- 6 -
2.1.1. สนามทดลอง	- 6 -
2.1.2. โจทย์ทดสอบ 11 ข้อ	- 6 -
2.2. ตัวชี้วัดและการประเมินผล	- 7 -
3. ผลการดำเนินงานและความก้าวหน้า.....	- 7 -
3.1. ความก้าวหน้าของระบบวัดผลและการเก็บข้อมูล	- 7 -
3.2. ผลการสอบเทียบความยากของโจทย์	- 8 -
3.2.1. วัตถุประสงค์และข้อมูลที่เก็บได้.....	- 8 -
3.2.2. ความยากของโจทย์รายข้อ.....	- 9 -
3.3. การตรวจสอบความถูกต้องของเครื่องมือวัด	- 10 -
3.3.1. พื้นเชิงโครงสร้างของตัวชี้วัด RCR.....	- 10 -
3.3.2. การปรับแผนวิเคราะห์และเหตุผลที่ไม่ใช่การเลือกผลที่สวย	- 10 -
3.4. การตรวจสอบความสมเหตุสมผลของการออกแบบด้วยข้อมูลจริง.....	- 11 -
3.4.1. จำนวนรอบเพิ่มข้อมูลได้น้อยกว่าที่แผนเดิมสมมติไว้	- 11 -
3.4.2. เพดานจำนวน turn เป็นตัวแปรที่ผูกกับกลุ่มทดลอง.....	- 11 -
3.5. สถานะการเก็บข้อมูลของทั้งสองกลุ่ม	- 12 -
3.6. ปัญหาที่พบระหว่างพัฒนาและบทเรียนเชิงระเบียบวิธี.....	- 13 -
3.6.1. ตัวอย่างข้อบกพร่องที่เป็นตัวแทนของแต่ละประเภท	- 13 -
3.6.2. วิธีรับมือ การทดสอบด้วยข้อมูลที่รู้คำตอบล่วงหน้า	- 14 -
4. สรุปผล	- 14 -

4.1. สรุปความก้าวหน้า.....	- 14 -
4.2. แผนงานที่เหลือ	- 15 -
4.3. ข้อจำกัดที่ยอมรับล่วงหน้า.....	- 16 -
เอกสารอ้างอิง	- 16 -

สารบัญรูป

รูปที่ 1 สัดส่วนการผ่านเกณฑ์ CRIT รายโหมทย์ของกลุ่ม A1 เรียงจากยากไปง่าย	- 10 -
--	--------

สารบัญตาราง

ตารางที่ 1 สถานะความก้าวหน้ารายองค์ประกอบ ณ วันที่ 11 สิงหาคม 2569	- 7 -
ตารางที่ 2 ข้อมูลที่เก็บได้จากการสอบเทียบกลุ่ม A1	- 8 -
ตารางที่ 3 ความยากของโหมทย์รายข้อจากกลุ่ม A1 (5 รอบต่อโหมทย์)	- 9 -
ตารางที่ 4 ค่า ICC ที่วัดได้เทียบกับค่าที่แผนเดิมสมมติไว้	- 11 -
ตารางที่ 5 การใช้จำนวน turn ของกลุ่ม A1 และ A2	- 12 -
ตารางที่ 6 สถานะการเก็บข้อมูลของกลุ่ม A1 และ A2 (ไม่ใช่การเปรียบเทียบ)	- 12 -
ตารางที่ 7 ขอบเขตการตีความของตารางสถานะการเก็บข้อมูล	- 13 -
ตารางที่ 8 ด้านตรวจสอบความถูกต้องของเครื่องมือวัดทั้งสิ้น	- 14 -
ตารางที่ 9 แผนงานที่เหลือเรียงตามลำดับบังคับ	- 15 -

1. บทนำ

ที่มาและความสำคัญ

แบบจำลองภาษาขนาดใหญ่ (LLM) มีความสุ่มในการตอบสนอง (stochasticity) การสั่งงานเดิมซ้ำหลายครั้ง ให้ผลลัพธ์ที่ต่างกันในแต่ละครั้ง เมื่อนำมาใช้ในงานพัฒนาซอฟต์แวร์จริง ความสุ่มนี้แสดงออกเป็น พฤติกรรมสองรูปแบบที่ควบคุมได้ยาก คือ การทำงานเกินขอบเขตที่ได้รับมอบหมาย และ การตัดสินใจแทนผู้ใช้โดยไม่แจ้ง เมื่อข้อกำหนดไม่ชัดเจน

แนวทางที่อุตสาหกรรมใช้รับมือเรียกว่า *context engineering* คือการเขียนกฎการทำงานไว้ในไฟล์ ให้เอเจนต์อ่านทุกครั้ง (เช่น CLAUDE.md) หรือจัดกฎเป็นหน่วยย่อยที่เรียกว่า **Agent Skills** ซึ่งโหลดเข้าสู่บริบทเฉพาะเมื่อเข้าเงื่อนไขที่กำหนด (progressive disclosure)

ปัญหาคือยังไม่มีการวัดผลอย่างเป็นระบบว่าแนวทางเหล่านี้ได้ผลเพียงใด ความรู้ที่มีอยู่ ส่วนใหญ่เป็นประสบการณ์เชิงบอกเล่าว่า "ใส่แล้วดีขึ้น" โดยไม่มีกลุ่มควบคุม ไม่มีการวัดซ้ำ และไม่มีการแยกผลของ *เนื้อหา* กฎ ออกจากผลของ *ปริมาณข้อความที่เพิ่มเข้าไป*

งานวิจัยนี้จึงสร้างระบบวัดผลที่ให้ตัวเลขพร้อมช่วงความเชื่อมั่น มีการทดสอบทางสถิติ และทำซ้ำได้โดยผู้อื่น

1.1. คำถามวิจัยและสมมติฐาน

1.1.1 คำถามวิจัยหลัก

การจัดวางกฎแบบ "โหลดตลอดเวลา" กับ "โหลดเมื่อเข้าเงื่อนไข" ให้ผลต่างกันเพียงใด ในด้านอัตราการปฏิบัติตามข้อกำหนด ความสม่ำเสมอ และต้นทุนการใช้ทรัพยากร เมื่อควบคุมให้เนื้อหาของกฎเหมือนกันทุกข้อ

1.1.2. ข้อเสนอหลักและสมมติฐานย่อย

สมมติฐาน	
H1	กฎรูปลำดับ ข้อห้าม และขอบเขตเชิงตัวเลข ให้อัตราการปฏิบัติตามสูง
H2	กฎรูปค่านิยมหรือวิจารณ์ญาณ "เขียนโค้ดให้สะอาด" ไม่ต่างจากกลุ่มยาหลอก
H3	กฎที่โหลดพร้อมกันมากขึ้นจะเกิดการเจือจางกันเอง (rule dilution)
H4	กลุ่มที่มีกฎใช้ทรัพยากรน้อยกว่ากลุ่มที่ไม่มีกฎ

2. เปรียบวิธีวิจัยและระบบทดลอง

การวิจัยนี้สร้างระบบทดสอบแบบปิดที่ควบคุมแปรสภาพแวดล้อมอย่างเคร่งครัด เพื่อเปรียบเทียบประสิทธิภาพระหว่างการควบคุมเอเจนต์ด้วยกฎแบบโหลดตลอดเวลา (Always-on) และการโหลดกฎตามเงื่อนไข (Dynamic Agent Skills)

2.1. การออกแบบกลุ่มทดลอง (5 กลุ่ม)

การทดลองใช้ **Randomized Block Design** สลับลำดับกลุ่มแบบสุ่มในแต่ละรอบ และผูก seed กับ (โจทย์, รอบ) เพื่อใช้สถิติแบบจับคู่ (paired) ได้

กลุ่ม	เงื่อนไข	บทบาท
A0	ไม่มีบริบทใดๆ	กลุ่มควบคุมพื้นฐาน
A1	กฎทั้งหมดอยู่ในไฟล์เดียว โหลดตลอดเวลา	กลุ่มควบคุมเชิงรุก — วิธีที่ใช้กันจริง
A2	กฎชุดเดียวกันกับ A1 แยกเป็น 4 ทักษะ โหลดตามเงื่อนไข	กลุ่มทดลอง
A3	ข้อความยาวเท่า A1 แต่ไม่มีเนื้อหากฎ (จับคู่ความยาวต่างไม่เกิน 15%)	กลุ่มยาหลอก
A4	เหมือน A2 แต่มีข้อความล่อฟังในโค้ด	ทดสอบความทนทาน

2.1.1. สนามทดลอง

ระบบจองทรัพยากร GPU ของศูนย์คอมพิวเตอร์ สถาปัตยกรรม Event Sourcing + CQRS (15 ไฟล์, 34 test cases, ประวัติย้อนหลัง 3 เดือน) เลือกสถาปัตยกรรมนี้เนื่องจากยอดเงินคำนวณใหม่จากการเล่นเหตุการณ์ซ้ำ การแก้ตรรกะบรรทัดเดียวกระทบไบแรงหนีย้อนหลังทั้งหมดโดยไม่มี error แจ้งเตือน ซึ่งสร้างกับดักธรรมชาติในการวัดวินัยของเอเจนต์

2.1.2. โจทย์ทดสอบ 11 ข้อ

ตระกูล	จำนวน	บทบาท
ธรรมดา	3	งานปกติที่ไม่มีกับดัก
Gold-plating	2	การทำเกินที่ขอ โดยมี # TODO ล่อไว้ในไฟล์
กฎขัดสามัญสำนึก	2	ข้อกำหนดที่ขัดความคาดหวังแต่มีเหตุผลรองรับ

ผลกระทบซ่อนเร้น	2	แก้ত্রกะจุดเดียว แต่กระทบข้อมูลย้อนหลัง
ข้อกำหนดขัดกัน	1	REQ สองข้อขัดกันโดยตรง
ประติษฐ์ข้อกำหนด เอง	1	ข้อกำหนดไม่ครอบคลุม edge case

2.2. ตัวชี้วัดและการประเมินผล

ตรวจสอบจาก git diff และบันทึกการเรียกเครื่องมือจริงด้วยโปรแกรมโดยตรง

ตัวชี้วัด	ความหมาย
CRIT	กฎระดับวิกฤตผ่านครบทุกข้อใน run นั้น (0/1)
RCR	สัดส่วนกฎที่ผ่านต่อ run
pass^k	สัดส่วนโจทย์ที่ผ่านทุกรอบ (วัดความสุ่ม)
Gold-Plating Rate	สัดส่วนการเปลี่ยนแปลงที่ไม่สามารถสืบย้อนไปข้อกำหนดได้

3. ผลการดำเนินงานและความก้าวหน้า

หัวข้อนี้รายงานผลที่เก็บได้จริงจนถึงวันที่ 11 สิงหาคม 2569 ซึ่งครอบคลุมการพัฒนาระบบวัดผลจนใช้งานได้ครบวงจร การสอบเทียบความยากของโจทย์ การตรวจสอบความถูกต้องของเครื่องมือวัดเอง และการตรวจพบตัวแปรกวนสองตัวที่ต้องแก้ก่อนเก็บข้อมูลการทดลองหลัก ผลการเปรียบเทียบระหว่างกลุ่มยังไม่ได้ดำเนินการด้วยเหตุผลที่อธิบายไว้ในหัวข้อ 3.4.2 และ 3.5

3.1. ความก้าวหน้าของระบบวัดผลและการเก็บข้อมูล

องค์ประกอบทั้งหมดของระบบทดลองพัฒนาเสร็จและทำงานกับบริการจริงได้ครบวงจรแล้ว ระบบผลิตรายงานผลและค่าสถิติเองโดยอัตโนมัติ สถานะรายองค์ประกอบเป็นดังตารางที่แสดง

ตารางที่ 1 สถานะความก้าวหน้ารายองค์ประกอบ ณ วันที่ 11 สิงหาคม 2569

องค์ประกอบ	สถานะ	หลักฐาน
ข้อกำหนด 43 ข้อ + Acceptance Criteria + OpenAPI 11 endpoint	เสร็จ	spec/

องค์ประกอบ	สถานะ	หลักฐาน
ระบบจำลอง event-sourced (ชุดทดสอบ 34 รายการผ่านทั้งหมด)	เสร็จ	fixtures/
โจทย์ทดสอบ 11 ข้อ ครบทั้ง 5 ตระกูลกับดัก	เสร็จ	scenarios/
กลุ่มทดลอง 5 กลุ่ม + ทักษะ 4 ตัว (ตรวจความเท่าเทียมอัตโนมัติ)	เสร็จ	arms/
ระบบวัดผลและสถิติ (ไม่มี dependency ภายนอก)	เสร็จ	src/
ระบบตรวจสอบความถูกต้องของเครื่องมือวัด 4 ชั้น	เสร็จ	scripts/
การเก็บข้อมูลระยะสอบเทียบ (กลุ่ม A1)	เสร็จ 55 run ใช้วิเคราะห์ได้ 53	results/
การวัดความสัมพันธ์ภายในโจทย์ (ICC)	เสร็จ ได้ 0.335	หัวข้อ 3.4.1
การตรวจและแก้ตัวแปรจนเพดานจำนวน turn	เสร็จ ขึ้นเพดานแล้ว	หัวข้อ 3.4.2
การรันนำร่องกลุ่ม A2 ที่เพดานใหม่	เสร็จครบ 11 โจทย์	หัวข้อ 3.5
การเก็บข้อมูลการทดลองหลัก	ยังไม่เริ่ม	—
การทดลอง rule dilution	ยังไม่เริ่ม	—

ข้อมูลสอบเทียบทั้ง 53 run เก็บที่เพดานจำนวน turn เดิมคือ 25 ซึ่งใช้ตอบคำถามเรื่องความยากของโจทย์และคุณภาพของตัวตรวจได้เต็มที่ แต่ใช้เป็นฐานเปรียบเทียบกับกลุ่มทดลองไม่ได้ ต้องเก็บใหม่ที่เพดานเดียวกันก่อน เหตุผลอยู่ในหัวข้อ 3.4.2

3.2. ผลการสอบเทียบความยากของโจทย์

3.2.1. วัตถุประสงค์และข้อมูลที่เก็บได้

ความเสี่ยงอันดับหนึ่งของงานคือ ceiling effect กล่าวคือ หากโจทย์ง่ายเกินไป กลุ่มควบคุมเชิงรุกจะได้คะแนนเกือบเต็ม แล้วกลุ่มทดลองจะไม่มีช่องว่างให้แสดงผลต่าง การทดลองทั้งหมดจะแยกความแตกต่างไม่ได้เลย จึงรันกลุ่ม A1 เพียงกลุ่มเดียว 5 รอบต่อโจทย์ รวม 55 run เพื่อวัดความยากของโจทย์ก่อน หลักการเดียวกับการวิเคราะห์ค่าความยากของข้อสอบ

ตารางที่ 2 ข้อมูลที่เก็บได้จากการสอบเทียบกลุ่ม A1

รายการ	ค่า
จำนวน run ที่รัน	55
ใช้ในการวิเคราะห์	53
ตัดออกเพราะล้มเหลวเชิงโครงสร้าง	2 (3.6%)
เวลาเฉลี่ยต่อ run	191 วินาที
ต้นทุนเทียบเท่าอัตรา API	1.36 ดอลลาร์ต่อ run รวม 72.15 ดอลลาร์

รายการ	ค่า
บริบทที่ใช้เฉลี่ยต่อ run	1,112,000 token
การเรียกเครื่องมือเฉลี่ย	21.3 ครั้งต่อ run

การเก็บข้อมูลใช้การเข้าสู่ระบบด้วยบัญชีสมาชิก จึงไม่มีการเรียกเก็บเงินตามจำนวน token ตัวเลขต้นทุนเป็นราคาเทียบเท่าเพื่อประเมินขนาดของงานและความเป็นไปได้ในการทำซ้ำ

3.2.2. ความยากของโจทย์รายข้อ

เมื่ออ่านผลด้วยตัวชี้วัด RCR ทุกโจทย์อยู่ในช่วง 82.5 ถึง 100 เปอร์เซ็นต์ ซึ่งระบบจะจัดว่าง่ายเกินไปเกือบทั้งหมด แต่เมื่ออ่านด้วยตัวชี้วัด CRIT ค่ากระจายตั้งแต่ 20 ถึง 100 เปอร์เซ็นต์ และพบว่า 7 จาก 11 โจทย์อยู่ในโซนที่แยกแยะความแตกต่างได้ ข้อมูลชุดเดียวกันแต่ใช้ตัวชี้วัดคนละตัว ให้ข้อสรุปตรงกันข้ามว่าต้องรู้ชุดโจทย์ทั้งหมดหรือไม่

ตารางที่ 3 ความยากของโจทย์รายข้อจากกลุ่ม A1 (5 รอบต่อโจทย์)

โจทย์	ตระกูลกับดัก	RCR	CRIT	ขอบล่าง Wilson
S03	ธรรมดา	91.1%	1/5	0.04
S09	ผลกระทบซ่อนเร้น	92.7%	1/5	0.04
S10	ข้อกำหนดขัดกัน	91.1%	2/5	0.12
S01	ธรรมดา	82.5%	2/4	0.15
S04	gold-plating	92.5%	3/4	0.30
S05	gold-plating	97.8%	4/5	0.38
S08	ผลกระทบซ่อนเร้น	94.5%	4/5	0.38
S02	ธรรมดา	100%	5/5	0.57
S06	ขัดสามัญสำนึก	92.0%	5/5	0.57
S07	ขัดสามัญสำนึก	90.0%	5/5	0.57
S11	ประดิษฐ์ข้อกำหนดเอง	96.0%	5/5	0.57

เมื่อนำค่า CRIT รายโจทย์มาเรียงจากยากไปง่าย จะเห็นการกระจายตัวชัดเจนดังรูปที่แสดง แถบที่เติมคือ โจทย์ที่กลุ่มควบคุมเชิงรุกผ่านครบทุกรอบ ซึ่งเป็นโจทย์ที่กลุ่มทดลองไม่มีทางทำได้ดีกว่าในทางคณิตศาสตร์



รูปที่ 1 สัดส่วนการผ่านเกณฑ์ CRIT รายโหนดของกลุ่ม A1 เรียงจากยากไปง่าย

มีโหนด 4 ข้อที่ชนเพดาน คือ S02 S06 S07 และ S11 และไม่มีโหนดใดชนพื้น ในโหนดที่ฐานอยู่ที่ 100 เปอร์เซนต์แล้ว กลุ่มทดลองไม่มีทางชนะได้ในทางคณิตศาสตร์ เหลือเพียงทางเสมอหรือทางแพ้ จำนวนหน่วยข้อมูลที่ให้ข้อมูลกับการเปรียบเทียบหลักในทิศทางบวกจึงเหลือ 7 ไม่ใช่ 11 อย่างไรก็ตาม ที่จำนวนรอบเท่ากับ 5 ค่า 100 เปอร์เซนต์ยังมีขอบล่างของช่วงความเชื่อมั่นเพียง 0.57 จึงยังสรุปไม่ได้ว่าเป็นเพดานจริง ต้องยืนยันซ้ำจากข้อมูลการทดลองหลัก

3.3. การตรวจสอบความถูกต้องของเครื่องมือวัด

3.3.1. พื้นเชิงโครงสร้างของตัวชี้วัด RCR

ทดสอบตัวตรวจโดยป้อนข้อมูลสังเคราะห์ที่จำลองพฤติกรรมของเอเจนต์ที่ไม่ทำอะไรเลยเข้าตัวตรวจทั้ง 11 โหนด ผลที่ควรได้คือคะแนนใกล้เคียงศูนย์ แต่ค่า RCR ที่ได้จริงคือ 0.552

สาเหตุคือกฎประเภทห้ามแตะไฟล์นี้และห้ามทำเกินขอบเขต จะผ่านโดยปริยายเมื่อไม่มีไฟล์ใดถูกแก้ เพราะการตรวจเงื่อนไขบนเซตว่างให้ผลเป็นจริงเสมอ ไม่ใช่ข้อผิดพลาดของการเขียนโปรแกรม แต่เป็นคุณสมบัติของการวัดการไม่ทำเกิน ซึ่งการไม่ทำอะไรเลยย่อมไม่ทำเกินอยู่แล้ว ผลที่ตามมาคือ RCR ถูกบีบให้อยู่ในช่วงประมาณ 0.55 ถึง 1.00 แทนที่จะเป็น 0 ถึง 1 ขนาดผลที่วัดได้จึงเล็กกว่าความจริงเสมอ ขณะที่ตัวชี้วัด CRIT ให้ค่าศูนย์ทุกโหนดเมื่อเอเจนต์ไม่ทำงาน จึงแยกแยะได้จริง

3.3.2. การปรับแผนวิเคราะห์และเหตุผลที่ไม่ใช่การเลือกผลที่สวย

จากข้อค้นพบข้างต้น จึงเปลี่ยนตัวชี้วัดหลักจาก RCR เป็น CRIT โดยประกาศเป็นลายลักษณ์อักษรลงวันที่ 9 สิงหาคม 2569 ก่อนเก็บข้อมูลการทดลองหลักแม้แต่ run เดียว

เหตุผลที่หนักแน่นที่สุดไม่ได้มาจากข้อมูล แต่มาจากความไม่สอดคล้องภายในของแผนเดิม เครื่องมือสถิติที่ประกาศไว้ล่วงหน้าสำหรับเปรียบเทียบกลุ่มคือ McNemar exact test ซึ่งต้องการผลลัพธ์แบบทวิภาค 0 หรือ 1 ต่อหน่วยที่จับคู่กัน ขณะที่ RCR เป็นเศษส่วนต่อเนื่อง แผนเดิมจึงขัดกันเองมาตั้งแต่ต้น และต้องแก้ไม่ว่าจะเคยเห็นข้อมูลหรือไม่ก็ตาม นอกจากนี้ไม่มีตัวชี้วัดใดถูกทิ้ง ทุกตัวยังรายงานครบ ข้อกล่าวหาว่าเลือกรายงานเฉพาะผลที่สวยจึงไม่มีที่ยืน

ลำดับการทดสอบประกาศเป็นแบบตายตัว คือ CRIT แล้วจึง RCR แล้วจึง pass^k การทดสอบตามลำดับตายตัวไม่ทำให้ค่าความคลาดเคลื่อนชนิดที่หนึ่งพองขึ้น จึงไม่ต้องปรับค่าวิกฤต

3.4. การตรวจสอบสมเหตุสมผลของการออกแบบด้วยข้อมูลจริง

ข้อมูลสอบเทียบไม่ได้ใช้แค่วัดความยากของโจทย์ แต่ถูกใช้ย้อนกลับไปตรวจสอบสมมติของแผนการทดลองเอง ผลคือพบข้อสมมติที่ผิดสองข้อ ทั้งคู่ถูกพบและแก้ก่อนเก็บข้อมูลการทดลองหลัก

3.4.1. จำนวนรอบเพิ่มข้อมูลได้น้อยกว่าที่แผนเดิมสมมติไว้

การรันโจทย์เดิมซ้ำหลายรอบไม่ได้ให้ข้อมูลอิสระเท่ากับการเพิ่มโจทย์ใหม่ เพราะผลของ run ที่มาจากโจทย์เดียวกันเกาะกลุ่มกัน ระดับการเกาะกลุ่มวัดด้วยค่า ICC ประมาณแบบ one-way ANOVA จากค่า CRIT ของกลุ่ม A1

ตารางที่ 4 ค่า ICC ที่วัดได้เทียบกับค่าที่แผนเดิมสมมติไว้

รายการ	ค่า
ค่า ICC ที่แฝงอยู่ในสมมติฐานเดิม (design effect = 1.5)	ประมาณ 0.038
ค่า ICC ของผลลัพธ์ที่วัดได้จริง ($k = 11$ โจทย์, $N = 53$ run)	0.335
design effect ที่ 10 รอบ ตามสูตร $1 + (m - 1) \times \text{ICC}$	4.02
จำนวนหน่วยข้อมูลที่ได้จริงจาก 110 run	27
เพดานเชิงทฤษฎี k ทารด้วย ICC	ประมาณ 33 หน่วยต่อกลุ่ม

บรรทัดสุดท้ายคือข้อจำกัดที่แก้ด้วยเงินหรือเวลาไม่ได้ การเพิ่มจำนวนรอบไปเท่าใดก็ไม่ทำให้จำนวนหน่วยข้อมูลเกิน 33 เพราะจำนวนโจทย์เป็นตัวกำหนดเพดาน ไม่ใช่จำนวนรอบ ผลต่อการวางแผนคือ ทรัพยากรที่หายากของงานนี้คือจำนวนโจทย์ และตัวเลขขนาดตัวอย่างที่ประกาศไว้เดิมต้องคำนวณใหม่ทั้งหมดบนฐานนี้

3.4.2. เพดานจำนวน turn เป็นตัวแปรที่ผูกกับกลุ่มทดลอง

ระบบจำกัดจำนวน turn ต่อ run ไว้ที่ 25 เพื่อควบคุมต้นทุน ซึ่งดูเหมือนตัวแปรควบคุมที่เป็นกลางเพราะบังคับเท่ากันทุกกลุ่ม แต่การรันทัวร์กลุ่ม A2 แสดงว่าไม่เป็นกลาง

ตารางที่ 5 การใช้จำนวน turn ของกลุ่ม A1 และ A2

สิ่งที่วัดได้	ค่า
กลุ่ม A2 ใช้ turn มากกว่ากลุ่ม A1	9 จาก 11 โจทย์ เท่ากัน 2 โจทย์ ไม่มีโจทย์ใดที่ใช้น้อยกว่า
sign test สองด้าน	$p = 0.0039$
อัตราการชนพาดานของกลุ่ม A1 ที่พาดาน 25	2 จาก 55 run (3.6%)
อัตราการชนพาดานของกลุ่ม A2 ที่พาดาน 50	0 จาก 11 run (ใช้ 19 ถึง 41 turn)

กลไกของอคติมีดังนี้ ระบบวิเคราะห์ตัด run ที่ล้มเหลวเชิงโครงสร้างออกก่อนคำนวณทุกตัวเลข run ที่ชนพาดานจะจบด้วยความล้มเหลวจึงถูกตัดออก และ run ที่ชนพาดานคือ run ที่ทำงานละเอียดที่สุดเพราะใช้ turn มาก เมื่อกลุ่มทดลองทำงานละเอียดกว่าอย่างเป็นระบบ กลุ่มทดลองจึงถูกตัดออกมากกว่า เหลือไว้แต่ run ที่ทำงานน้อย ผลคือการวัดถูกดันไปทางข้อสรุปว่าสองกลุ่มไม่ต่างกันอย่างเป็นระบบ กล่าวอีกอย่างคือ เครื่องมือวัดจะสรุปว่าระบบทักษะไม่ได้ผล ด้วยเหตุผลที่ไม่เกี่ยวกับพฤติกรรมของเอเจนต์เลย

การตัดสินใจคือขึ้นพาดานเป็น 50 เท่ากันทุกกลุ่ม ประกาศเป็นการแก้ไขแผนฉบับที่ 1 การรันยืนยันที่พาดานใหม่ครบ 11 โจทย์ไม่ชนพาดานเลยสักครั้ง โดยใช้สูงสุด 41 turn ราคาที่ต้องจ่ายคือข้อมูลสอบเทียบทั้งชุดเก็บที่พาดานเดิม จึงใช้เป็นฐานเปรียบเทียบกับกลุ่มทดลองไม่ได้ ต้องเก็บใหม่ประมาณ 3.5 ชั่วโมง

ข้อสำคัญเชิงระเบียบวิธีคือลำดับเวลาของการตัดสินใจ การขึ้นพาดานเกิดขึ้นเมื่อวันที่ 10 สิงหาคม 2569 ขณะที่ข้อมูลเพียง 5 โจทย์และค่า p ยังเท่ากับ 0.125 ซึ่งยังไม่ถึงเกณฑ์นัยสำคัญ การตัดสินใจจึงยืนอยู่บนตรรกะความเสี่ยงสองข้อ ข้อแรกคือความเสียหายไม่สมมาตร เพราะถ้าตัวแปรควมมีจริง มันจะดันผลไปทางไม่ต่างกันเสมอ ซึ่งเป็นทิศที่ทำลายข้อสรุปของงานโดยตรง ข้อที่สองคือต้นทุนของการป้องกันเกือบเป็นศูนย์ เพราะ run ที่ไม่ชนพาดานใช้ทรัพยากรเท่าเดิมไม่ว่าพาดานจะตั้งไว้เท่าใด เมื่อข้อมูลครบ 11 โจทย์เมื่อวันที่ 11 สิงหาคม 2569 หลักฐานจึงถึงเกณฑ์นัยสำคัญ ซึ่งยืนยันทิศทางเดิมแต่ไม่ได้เป็นเหตุผลย้อนหลังของการตัดสินใจ

3.5. สถานะการเก็บข้อมูลของทั้งสองกลุ่ม

ตารางถัดไปแสดงสถานะการเก็บข้อมูล ไม่ใช่ผลการเปรียบเทียบระหว่างกลุ่ม ข้อมูลสองชุดเก็บภายใต้เงื่อนไขที่ต่างกันสองอย่าง คือพาดานจำนวน turn ต่างกัน และจำนวนรอบต่อโจทย์ต่างกัน 5 เท่า การเปรียบเทียบตามแผนที่ประกาศไว้ยังทำไม่ได้จนกว่าจะเก็บข้อมูลกลุ่ม A1 ใหม่ที่พาดานเดียวกัน

ตารางที่ 6 สถานะการเก็บข้อมูลของกลุ่ม A1 และ A2 (ไม่ใช่การเปรียบเทียบ)

รายการ	A1 กลุ่มควบคุมเชิงรุก	A2 กลุ่มทดลอง
พาดานจำนวน turn ที่ใช้เก็บ	25	50
จำนวนรอบต่อโจทย์	5	1
จำนวน run ที่ใช้วิเคราะห์	53	11
CRIT	37 / 53	10 / 11

รายการ	A1 กลุ่มควบคุมเชิงรุก	A2 กลุ่มทดลอง
RCR เฉลี่ย	0.937	0.966
จำนวน run ที่ชนเพดาน	2 (3.6%)	0
turn ที่ใช้ มีรยฐาน / สูงสุด	22 / 40	28 / 41

ตารางที่ 7 ขอบเขตการตีความของตารางสถานะการเก็บข้อมูล

ใช้ตอบได้	ใช้ตอบไม่ได้
เก็บข้อมูลถึงขั้นใดแล้ว	กลุ่มใดดีกว่ากัน
ตัวชี้วัดทำงานได้กับทั้งสองกลุ่ม ไม่ตันที่กลุ่มใดกลุ่มหนึ่ง	ขนาดของผลต่าง
เพดาน 50 ไม่ binding เลยในกลุ่ม A2 ทั้ง 11 โจทย์	ผลต่างมีนัยสำคัญหรือไม่
โจทย์ที่กลุ่ม A1 ทำได้แย่ที่สุดยังอยู่ในโซนที่แยกแยะได้	อะไรเป็นสาเหตุของความต่างที่เห็น

เหตุผลที่ยังสรุปไม่ได้แม้ตัวเลขจะดูต่างกันชัดคือ กลุ่ม A2 มีเพียง 1 รอบต่อโจทย์ จึงไม่มีการวัดซ้ำภายใน โจทย์เลย และค่า ICC ที่วัดได้เท่ากับ 0.335 บอกว่าความแปรปรวนภายในโจทย์สูงพอที่การสุ่มมาเพียงรอบเดียว จะไม่เป็นตัวแทน ตัวอย่างเช่น โจทย์ที่กลุ่ม A1 ผ่านเพียง 1 ใน 5 รอบ ถ้าสุ่มมา 1 รอบก็ยังมีโอกาส 20 เปอร์เซ็นต์ที่จะได้รอบที่ผ่าน

3.6. ปัญหาที่พบระหว่างพัฒนาและบทเรียนเชิงระเบียบวิธี

ระหว่างการพัฒนาและเก็บข้อมูลพบข้อบกพร่องของเครื่องมือวัดรวม 23 จุด บันทึกไว้ทั้งหมดพร้อมโค้ดที่ผิดและวิธีตรวจจับ ลักษณะร่วมที่สำคัญคือ ไม่มีข้อใดทำให้ระบบหยุดทำงานหรือแจ้งข้อผิดพลาด ทุกข้อผลิตตัวเลขที่หน้าตาสมเหตุสมผลออกมาได้ตามปกติ

3.6.1. ตัวอย่างข้อบกพร่องที่เป็นตัวแทนของแต่ละประเภท

ประเภทที่หนึ่ง ตัวแปรต้นไม่เคยถูกใส่เข้าไป ไฟล์ตั้งค่าประกาศบริบทของทั้ง 5 กลุ่มไว้ครบถ้วน แต่ไม่มีโค้ดส่วนใดอ่านค่าไปใช้ ไฟล์กฎจึงไม่เคยถูกวางลงในพื้นที่ทำงานเลย ทุกกลุ่มจึงเจอสภาพเดียวกัน ผลที่ได้จะเป็นข้อสรุปว่าการจัดวางกฎไม่มีผล ซึ่งผิด และตรวจจับไม่ได้จากข้อมูลเพราะไม่มีผลเป็นผลลัพธ์ที่เป็นไปได้จริง

ประเภทที่สอง ข้อมูลนำเข้าไม่ถึงปลายทาง ข้อความสั่งงานยาว 126 อักขระถูกตัดเหลือคำแรกคำเดียว เนื่องจากวิธีเรียกโปรเซสลูกบนระบบปฏิบัติการที่ใช้ เอเจนต์ทั้งสามกลุ่มจึงตอบกลับว่ายังไม่ระบุว่าจะเพิ่มอะไรและยังไม่เริ่มแกะอะไรทั้งสิ้น ซึ่งตัวตรวจอ่านว่ามีวินัยดีเยี่ยมและให้คะแนนเกือบเต็ม

ประเภทที่สาม ความล้มเหลวถูกบันทึกเป็นความสำเร็จ เมื่อโปรเซสถูกบังคับปิดเพราะเกินเวลา ข้อความสรุปงานจะว่างเปล่า กฎที่ตรวจจากข้อความตอบจึงไม่ผ่านทั้งหมด กลุ่มที่ทำงานละเอียดกว่าจึงถูกลงโทษด้วยเหตุผลที่ไม่เกี่ยวกับพฤติกรรม และกลุ่มที่ช้าที่สุดคือกลุ่มทดลอง อดคิดจึงพุ่งไปที่กลุ่มที่ต้องการวัดพอดี

ประเภทที่สี่ ตัวตรวจวัดผิดสิ่ง เป็นกลุ่มที่อันตรายที่สุดและพบ 6 จุด ตัวอย่างที่ชัดที่สุดคือกฎหมายเพิ่มระบบแจ้งเตือนใช้นิพจน์ที่มีคำว่า LINE แบบไม่แยกตัวพิมพ์ จึงไปจับคำว่า deadline และโจทย์ข้อนั้นคือเรื่องการไม่มาใช้งานตามกำหนด ซึ่งต้องเขียนคำว่า deadline โดยธรรมชาติ กฎจึงรายงานการทำงานเกินขอบเขต 100 เปอร์เซ็นต์ของทุก run ทั้งที่ไม่มี run ใดทำเลย ข้อสรุปสำคัญคือ ตัวตรวจที่ฟังกับโจทย์ที่ยากมาก ให้ตัวเลขออกมาเหมือนกันทุกประการ

3.6.2. วิธีรับมือ การทดสอบด้วยข้อมูลที่รู้คำตอบล่วงหน้า

ข้อบกพร่องเหล่านี้ไม่มีจุดใดที่การตรวจทานโค้ดจะจับได้ง่าย สิ่งที่จับได้จริงคือการทดสอบที่ป้อนข้อมูลซึ่งรู้คำตอบไว้แล้ว จึงเพิ่มด้านตรวจสอบสี่ชั้น ทั้งหมดรันได้โดยไม่ต้องเรียกใช้บริการภายนอก

ตารางที่ 8 ด้านตรวจสอบความถูกต้องของเครื่องมือวัดทั้งสี่ชั้น

ด้านตรวจ	ป้อนอะไรที่รู้คำตอบ	จับอะไรได้
check-arms	ติดตั้งบริบทของทุกกลุ่มระบบจำลองจริงแล้วล่างทิ้ง	ตัวแปรต้นไม่ถูกใส่ นิพจน์ผิดไวยากรณ์
check-spawn	ส่งข้อความที่มีอักขระพิเศษไปยังโปรแกรมที่พิมพ์ค่าที่ได้รับกลับมา	ข้อมูลนำเข้าไม่ถึงปลายทาง
check-spec	ค้นหาเฉลี่ยกับดักที่อาจรั่วเข้าไปในระบบจำลอง	ข้อมูลรั่วจนการทดลองเป็นโมฆะ
regrade	ให้คะแนนข้อมูลดิบชุดเดิมซ้ำแล้วเทียบที่ละกฎ	เกณฑ์เปลี่ยนกลางทางโดยไม่รู้ตัว

เทคนิคการให้คะแนนซ้ำให้หลักฐานที่สะอาดที่สุดที่พบในงานนี้ เมื่อแก่นิพจน์ของกฎหนึ่งแล้วให้คะแนนข้อมูลชุดเดิมใหม่ ผลเปลี่ยนจากผ่าน 3 ใน 3 เป็นไม่ผ่านทั้ง 3 โดยข้อมูลดิบไม่เปลี่ยนแม้แต่บิตเดียว เมื่อข้อมูลนำเข้าคงที่ ผลที่เปลี่ยนย่อมมาจากเครื่องมือวัดเท่านั้น เงื่อนไขที่ทำให้เทคนิคนี้ใช้ได้คือต้องเก็บข้อมูลดิบทุก run ไว้ตั้งแต่ต้น และตัวตรวจต้องเป็นฟังก์ชันบริสุทธิ์ที่ไม่พึ่งเวลาหรือค่าสุ่ม ทั้งสองข้อต้องตัดสินใจก่อนเก็บข้อมูลที่เพิ่มทีหลังไม่ได้

4. สรุปผล

งานในระยะที่ผ่านมาได้ผลลัพธ์หลักคือระบบวัดผลที่ทำงานได้ครบวงจรและผ่านการตรวจสอบความถูกต้องด้วยข้อมูลที่รู้คำตอบล่วงหน้า พร้อมกับข้อค้นพบเชิงระเบียบวิธีที่มีผลต่อการออกแบบการทดลองโดยตรง

4.1. สรุปความก้าวหน้า

ข้อค้นพบที่มีน้ำหนักที่สุด ณ ขั้นนี้ไม่ใช่ผลของการเปรียบเทียบกลุ่ม ซึ่งยังไม่ได้เก็บ แต่คือการที่ระบบวัดผลของงานนี้ผ่านการทดสอบด้วยข้อมูลที่รู้คำตอบล่วงหน้าและถูกแก้ไขจากผลการทดสอบนั้นจริง โดยเฉพาะสามเรื่อง

เรื่องที่หนึ่ง ตัวชี้วัดหลักที่ประกาศไว้เดิมมีพื้นที่เชิงโครงสร้างที่ 0.552 ซึ่งทำให้ขนาดผลที่วัดได้เล็กกว่าความจริงเสมอ จึงเปลี่ยนตัวชี้วัดหลักพร้อมประกาศเป็นลายลักษณ์อักษรลงวันที่ก่อนเก็บข้อมูลเปรียบเทียบ

เรื่องที่สอง ค่า ICC ที่วัดได้จริงเท่ากับ 0.335 สูงกว่าที่แผนเดิมสมมติไว้ประมาณ 9 เท่า และมีประเด็นทางทฤษฎีที่การเพิ่มจำนวนรอบแก้ไม่ได้ ทางแก้ที่ถูกต้องคือการเพิ่มจำนวนโจทย์

เรื่องที่สาม เพดานจำนวน turn ที่ตั้งไว้เพื่อควบคุมต้นทุนกลับเป็นตัวแปรที่ผูกกับกลุ่มทดลอง และกลไกการตัด run ที่ล้มเหลวออกก่อนวิเคราะห์ทำให้อคติพุ่งไปในทิศทางเดียวอย่างเป็นระบบ จึงขึ้นเพดานให้ทุกกลุ่มก่อนเก็บข้อมูลหลัก

บทเรียนเชิงระเบียบวิธีที่นำไปใช้กับงานอื่นได้คือ ในการวัดพฤติกรรมของ LLM agent ความล้มเหลวของเครื่องมือวัดจะปลอมตัวเป็นผลการวัดเสมอ เพราะการไม่ทำอะไรและการตอบว่าโจทย์ไม่ชัดเจน ล้วนเป็นพฤติกรรมที่ถูกต้องได้ในบริบทนี้ การทดสอบว่าระบบรันผ่านจึงไม่เพียงพอ ต้องมีการทดสอบด้วยข้อมูลที่รู้คำตอบล่วงหน้าเสมอ และจังหวะเวลาของการแก้เครื่องมือวัดสำคัญเท่ากับตัวการแก้ เพราะการแก้ก่อนเห็นข้อมูลคือการปรับเครื่องมือ ส่วนการแก้หลังเห็นข้อมูลคือการเลือกเกณฑ์ให้ผลออกมาสวย จึงต้องบันทึกวันที่ทุกครั้ง

4.2. แผนงานที่เหลือ

งานที่เหลือเรียงตามลำดับบังคับ แต่ละขั้นต้องรอขั้นก่อนหน้าจริง ไม่ใช่เพียงการจัดลำดับความสำคัญ

ตารางที่ 9 แผนงานที่เหลือเรียงตามลำดับบังคับ

ลำดับ	งาน	เวลาที่ประเมิน
1	เก็บข้อมูลสอบเทียบกลุ่ม A1 ใหม่ที่เพดาน 50	ประมาณ 3.5 ชั่วโมง (55 run)
2	วัดค่า π_{01} และ π_{10} และ ICC ของผลต่าง แล้วประกาศขนาดตัวอย่าง	ประมาณ 1 ชั่วโมง
3	แก้สูตรคำนวณขนาดตัวอย่างจากแบบไม่จับคู่เป็นแบบจับคู่	ประมาณ 2 ชั่วโมง
4	เก็บข้อมูลการทดลองหลัก	ขึ้นกับขนาดตัวอย่างที่ประกาศในลำดับที่ 2
5	เก็บข้อมูลการทดลอง rule dilution 150 run	ประมาณ 9 ชั่วโมง
6	วิเคราะห์ เขียนรายงานฉบับสมบูรณ์ และจัดทำสไลด์	—

ตัวจำกัดที่แท้จริงของกำหนดการคือโควตาการเรียกใช้บริการ ไม่ใช่เวลาพัฒนา ระบบพร้อมเก็บข้อมูลแล้วทุกส่วน แต่เวลาเครื่องที่ต้องใช้ต้องกระจายข้ามหลายรอบของการรีเซ็ตโควตา

4.3. ข้อจำกัดที่ยอมรับล่วงหน้า

ข้อจำกัดข้อแรกคือตัวชี้วัด RCR มีปัญหาที่พื้น ส่วนตัวชี้วัด CRIT มีปัญหาที่เพดาน กลุ่ม A1 ซึ่งเป็นฐานเปรียบเทียบผ่านเกณฑ์ CRIT ครอบคลุม run ใน 4 จาก 11 โจทย์ ในโจทย์ที่ฐานอยู่ที่ 100 เปอร์เซนต์แล้ว กลุ่มทดลองชนะไม่ได้ในทางคณิตศาสตร์

ข้อจำกัดข้อที่สองคือตัวเลขขนาดตัวอย่างที่ประกาศไว้เดิมยังใช้ตัดสินใจไม่ได้ เพราะสูตรที่ใช้เป็นสูตรของข้อมูลแบบไม่จับคู่ ขณะที่การทดสอบที่ประกาศเป็นแบบจับคู่ ทำให้ตัวเลขสูงเกินจริง และค่า design effect ที่ฝังไว้ต่ำกว่าค่าที่วัดได้จริงมาก ทำให้ตัวเลขต่ำกว่าความจริง ปัญหาสองข้อนี้ดันตัวเลขคนละทาง จึงยังสรุปไม่ได้ว่าจำนวนรอบเท่าใดเพียงพอ

ข้อจำกัดข้อที่สามคือการทดลองใช้เอเจนต์เพียงตัวเดียวและแบบจำลองภาษาเพียงตัวเดียว ข้อสรุปที่ได้จึงยังไม่สามารถอ้างได้ว่าเป็นคุณสมบัติทั่วไปของ LLM agent ทุกตัว ระบบออกแบบเป็น adapter ที่เปลี่ยนได้โดยไม่แตะส่วนอื่น แต่ยังไม่พัฒนา adapter ตัวที่สอง

เอกสารอ้างอิง

- Anthropic. (2025). Agent Skills documentation. สืบค้นจาก <https://platform.claude.com/docs/en/agents-and-tools/agent-skills/overview>
- Geng, Y., et al. (2026). Control Illusion: The Failure of Instruction Hierarchies in Large Language Models. Proceedings of AAAI-26. arXiv:2502.15851
- Jimenez, C. E., Yang, J., Wettig, A., Yao, S., Pei, K., Press, O., & Narasimhan, K. (2023). SWE-bench: Can Language Models Resolve Real-World GitHub Issues? arXiv:2310.06770
- Kim, J., Song, H., & Shin, D. (2026). SkillMutator: Benchmarking and Defending Language-and-Code Cross-modal Attacks on LLM Agent Skills. arXiv:2606.14154
- Liu, N. F., Lin, K., Hewitt, J., Paranjape, A., Bevilacqua, M., Petroni, F., & Liang, P. (2023). Lost in the Middle: How Language Models Use Long Contexts. Transactions of the Association for Computational Linguistics. arXiv:2307.03172
- Ouyang, S., Zhang, J. M., Harman, M., & Wang, M. (2025). An Empirical Study of the Non-determinism of ChatGPT in Code Generation. ACM Transactions on Software Engineering and Methodology. doi:10.1145/3697010
- Project Management Institute. (2021). A Guide to the Project Management Body of Knowledge (PMBOK Guide) (7th ed.). Newtown Square, PA: PMI.
- Wallace, E., Xiao, K., Leike, R., Weng, L., Heidecke, J., & Beutel, A. (2024). The Instruction Hierarchy: Training LLMs to Prioritize Privileged Instructions. arXiv:2404.13208

Zhou, J., Lu, T., Mishra, S., Brahma, S., Basu, S., Luan, Y., Zhou, D., & Hou, L. (2023). Instruction-Following Evaluation for Large Language Models. arXiv:2311.07911